

共通 データの分析

歩出問題2 パターン

- ・図表の読み取り... 文章から図表の参照
- ・計算

どちらにおいても、各用語の定義に忠実に扱うことが求められる

1次元データ $x_1, x_2, \dots, x_n$

← P番の人が
スコアという情報を
持つイメージ

2次元データ $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$

を用意する


1. 図表の読み取り

⑩ 各種図表について何が読み取れて

何が読み取れないかの把握

度数分布表の
視覚化

ヒストグラム



具体値 (Max, min, 四分位範囲(数)) はわからない

ある範囲(階級) にどれくらい含まれるか


↓ 大まかに4等分して箱ひげ図と対応できるように!

第1, 2, 3 四分位数

Q_1, Q_2, Q_3

箱ひげ図

散布図



Max, min 四分位範囲数はわかる
個々のデータの値はわからない

点は必ず3の区分内

四区分内の点の個数は同じ

相関係数の読み取り

中央値... データの**中点**を探すイメージ

操作

$$m = \frac{(\text{最初の番号}) + (\text{最後の番号})}{2}$$

データの中点として

$$\begin{cases} m \text{ が整数} & x_m \text{ (次の操作で除外)} \\ m \text{ が整数でない} & \frac{x_{m-\frac{1}{2}} + x_{m+\frac{1}{2}}}{2} \end{cases}$$

これを3回行って

4つのグループに分ける

四分位範囲

k を 1/x 上の整数とする

$n = 4k$

$x_1, x_k, x_{k+1}, x_{2k}, x_{2k+1}, x_{3k}, x_{3k+1}, x_{4k}$

$n = 4k+1$

$x_1, x_k, x_{k+1}, x_{2k+1}, x_{2k+2}, x_{3k+1}, x_{3k+2}, x_{4k+1}$

$n = 4k+2$

$x_1, x_{k+1}, x_{2k+1}, x_{2k+2}, x_{3k+2}, x_{4k+2}$

$n = 4k+3$

$x_1, x_{k+1}, x_{2k+2}, x_{3k+3}, x_{4k+3}$

2. 数式関係

平均 : $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ★平均だけなら (共)分散は要まる

分散 : $S_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

共分散 : $S_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$

標準偏差 : $S_x = \sqrt{S_x^2} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$


相関係数 : $r_{xy} = \frac{S_{xy}}{S_x S_y}$

ベクトルの内積の $1 \times -ジ$
 ベクトルの大きさの $1 \times -ジ$
 分母 $\frac{1}{n}$

ベクトルの成す角
の $\cos$ の $1 \times -ジ$
 $\cos = \frac{\bar{x} \cdot \bar{y}}{|\bar{x}| |\bar{y}|}$
ここから
 $-1 \leq r_{xy} \leq 1$ とわかる
(これはコーシーシュワルツの
不等式と同値)

相関係数... とだけデータが直線に近いか

→ 散布図との対応



$|r_{xy}| \geq 0.4$ を直線を感じられる (らしいw)

正(負)の相関が強い

= r_{xy} が 1 (-1) に近い

= データが直線っぽい

散布図から目関係数を当てる練習ができるサイト

<https://www.guessthecorrelation.com/>

これ以外の変数変換は
定義に戻って計算!

1次式による変換 (a倍, b平行移動量)

$$Z_i = a x_i + b \quad (i=1, 2, \dots, n) \text{ とすると}$$

$$\bar{z} = a \bar{x} + b \quad \leftarrow \text{仮平均}$$

$$S_z^2 = a^2 S_x^2$$

$$S_z = |a| S_x$$

$$S_{zy} = a S_{xy}$$

$$r_{zy} = \frac{a}{|a|} r_{xy}$$

$$= \begin{cases} a \geq 0 \text{ のとき } r_{xy} \\ a < 0 \text{ のとき } -r_{xy} \end{cases}$$

平均に近そうな値を $\bar{x}_{仮}$ とする

$$Z_i = x_i - \bar{x}_{仮} \text{ とすると}$$


↑ 値が小さくなり $\bar{z}$

は $\bar{x}$ より計算しやすい

$$\bar{x} = \bar{z} + \bar{x}_{仮}$$

(10)

相関係数の絶対値
は1次変換で不変



定義に戻って計算するときのコツ

$$\text{ex)} S_{xy} = \bar{x} \bar{y} - \bar{x} \bar{y} \text{ を示せ}$$

① 1つのデータ (1を取る前) に注目して計算

$$(x_i - \bar{x})(y_i - \bar{y}) = x_i y_i - \bar{x} y_i - x_i \bar{y} + \bar{x} \bar{y}$$

$$\textcircled{2} \sum_{i=1}^n (\text{定数}) f(i) = (\text{定数}) \sum_{i=1}^n f(i) \quad \text{定数}$$

(特に $\frac{1}{n} \sum (\text{定数}) = (\text{定数})$) に注意して $\frac{1}{n} \sum$ を取る

$$S_{xy} = \bar{x} \bar{y} - \bar{x} \frac{1}{n} \sum y_i - \bar{y} \frac{1}{n} \sum x_i + \bar{x} \bar{y}$$

標準化

データの平均を0, 標準偏差を1となるように変換

つまり $\bar{z} = 0, S_z = 1$

$$Z_i = \frac{x_i - \bar{x}}{S_x} \text{ とすることを標準化と言う}$$

データの合体

$$(x_1, x_2, \dots, x_n, y_1, y_2, \dots, y_m)$$

$$= (z_1, z_2, \dots, z_n, z_{n+1}, \dots, z_{n+m}) \text{ とすると}$$

$$\bar{z} = \frac{n \bar{x} + m \bar{y}}{n+m} \quad \leftarrow \begin{cases} \text{合体後} \\ \text{の平均} \end{cases} = \text{(重み付き平均)}$$

また

$$\bar{z}^2 = \frac{n \bar{x}^2 + m \bar{y}^2}{n+m} \text{ より } S_z^2 = (\bar{z}^2 - \bar{z}^2) \text{ 等求まる}$$

データの個数をかける
 $n \times \bar{x}$

仮説検定

対立仮説 (H_1) ← 通したい主張
 帰無仮説 (H_0) ← 否定したい主張
 事象 (A)
 有位水準

問題文
から把握
できると良い

- H_0 の下で統計量の分布を言う
- H_1 に有利な棄却域を決定する
有位水準を下に

- 事象 A が棄却域に
含まれる → H_0 は棄却、 H_1 を受容する
含まれない → H_0 は受容される

2025 試行調査 (検索すると問題出てくるので一度解いてみて下さい。仮説検定の知識無しでも解けます。)


太郎さんは、調べた空港のうちのひとつである P 空港で、利便性に関するアンケート調査が実施されていることを知った。

太郎: P 空港を利用した 30 人に、P 空港は便利かどうかをたずねたとき、どのくらいの人かが「便利だ」と回答したら、P 空港の利用者全体のうち便利だと思う人が多いとしてよいのかなあ。
 花子: 例えば、20 人だったらどうかなあ。

二人は、30 人のうち 20 人が「便利だ」と回答した場合に、「P 空港は便利だ」と思うのが多い」といえるかどうかを、次の方針で考えることにした。 **事象 A**
 方針 **対立仮説 H_1**

- 「P 空港の利用者全体のうちで「便利だ」と回答する割合と、「便利だ」と回答しない割合が等しい」という仮説を立てる。 **帰無仮説 H_0**
- この仮説が正しいと 30 人抽出したうちの 20 人以上が「便利だ」と回答する確率が 5% 未満であれば、その仮説は誤っていると判断し、5% 以上であれば、その仮説は誤っていないとは判断しない。 **有位水準 = 判断基準**

次の実験結果は、30 枚の硬貨を投げる実験を 1000 回行ったとき、表が出た枚数ごとの回数の割合を示したものである。



実験結果を用いると、30 枚の硬貨のうち 20 枚以上表となった割合は $\frac{20}{30}$ 、 $\frac{2}{3}$ である。これを、30 人のうち 20 人以上が「便利だ」と回答する確率とみなし、方針に従うと、「便利だ」と回答する割合と「便利だ」と回答しない割合が等しいという仮説は $\frac{2}{3}$ 、P 空港は便利だと思う人が $\frac{2}{3}$ 。


$\frac{2}{3}$ 、 $\frac{1}{3}$ については、最も適当なものを、次のそれぞれの解答群から一つずつ選べ。

☒ $\frac{2}{3}$ の解答群
 ① 誤っていると判断され ② 誤っているとは判断されず

☐ $\frac{1}{3}$ の解答群
 ① 多いといえる ② 多いとはいえない

最小二乗法

相関係数で「直線っぽい」という意見を扱った
 その延長としてデータに最も近い直線を考える
 直線 $y = ax + b$ について
 残差: $e_i = y_i - (ax_i + b)$ として



$\sum_{i=1}^n e_i^2$ が最小となるような a, b を求める
 $\sum e_i$ が 0 になる残差が打ち消し合ってしまう

(以下 $\sum_{i=1}^n$ を Σ と省略する) データに近い直線にならない

一般に $px^2 + qx + r$ ($p > 0$) の任意の実数 x における

最小値は $x = -\frac{q}{2p}$ で取ることに注意して

$$e_i^2 = (b + x_i a - y_i)^2$$

$$= b^2 + 2(x_i a - y_i)b + (x_i a - y_i)^2 \quad \because \frac{1}{n} \sum x_i = \bar{x}$$

$$\Sigma e_i^2 = nb^2 + 2n(a\bar{x} - \bar{y})b + \Sigma (x_i a - y_i)^2$$

より Σe_i^2 は $b = -\frac{2n(a\bar{x} - \bar{y})}{2n} = \bar{y} - a\bar{x}$ で最小値を取り

このとき

$$e_i^2 = \{(x_i - \bar{x})a - (y_i - \bar{y})\}^2$$

$$\Sigma e_i^2 = nS_x^2 a^2 - 2nS_x \bar{y} a + nS_y^2$$

より $a = \frac{-2S_x \bar{y}}{2S_x^2} = -\frac{S_x \bar{y}}{S_x^2}$ で最小値を取る

$$\pm \text{より } (a, b) = \left(-\frac{S_x \bar{y}}{S_x^2}, \bar{y} + \frac{S_x \bar{y}}{S_x^2} \bar{x} \right)$$

このときの $y = ax + b$ が Σe_i^2 が最小の直線

(これを回帰直線と呼ぶ) であり、このとき

$$0 \leq \Sigma e_i^2 = nS_y^2 \left\{ 1 - \left(\frac{S_x \bar{y}}{S_x S_y} \right)^2 \right\}$$

$\therefore -1 \leq r_{xy} \leq 1$ と相関係数 $|r_{xy}| \leq 1$ も示せる

また残差の性質として

$$\bar{e} = 0$$

$$S_{ex} = \Sigma (e_i - \bar{e})(x_i - \bar{x})$$

$$= \Sigma (y_i - \bar{y})(x_i - \bar{x}) - \frac{S_x \bar{y}}{S_x^2} \Sigma (x_i - \bar{x})^2$$

$$= 0$$

等がある